

**KARDIOLOG.AI: PENDEKATAN MULTI-MODAL TRIPLE
ENSEMBLE DAN EXPLAINABLE AI UNTUK SKRINING KELAINAN
SUARA JANTUNG (PCG)**

Dosen Pengampu:

ABU SALAM, M.Kom



Disusun oleh:

Nama : Ahmad Fauzi

NIM : A11.2024.15948

UNIVERSITAS DIAN NUSWANTORO

FAKULTAS ILMU KOMPUTER

SEMARANG

2026

Pendahuluan dan Latar Belakang

Fasilitas kesehatan tingkat pertama (Puskesmas atau Klinik) di banyak negara berkembang, termasuk Indonesia, seringkali mengalami keterbatasan akses terhadap dokter spesialis jantung (kardiolog) yang kompeten. Pada tahap awal pemeriksaan klinis, dokter umum masih sangat bergantung pada teknik auskultasi konvensional menggunakan stetoskop manual untuk mendengarkan dan menginterpretasikan bunyi detak jantung pasien. Pendekatan tradisional ini memiliki kelemahan yang sangat fundamental: akurasi diagnosis sangat bergantung pada tingkat kepekaan telinga pendengaran, jam terbang pengalaman klinis, dan tingkat kelelahan subjektif sang dokter pada saat pemeriksaan berlangsung. Akibatnya, anomali atau kelainan detak jantung yang samar, seperti murmur halus yang mengindikasikan kelainan struktur katup jantung, sering kali terlewatkan (misdiagnosis) atau sayangnya baru terdeteksi secara tidak sengaja ketika kondisi fisiologis pasien sudah memasuki stadium kritis atau komplikasi. Keterlambatan diagnosis awal ini secara langsung berkontribusi pada tingginya angka morbiditas dan mortalitas akibat penyakit kardiovaskular di tengah masyarakat.

Oleh karena itu, diperlukan sebuah terobosan teknologi mutakhir melalui pengembangan sistem Machine Learning berbasis kecerdasan buatan (AI) yang mampu menganalisis dan mendiagnosis kelainan suara detak jantung secara otomatis, objektif, dan bekerja secara real-time. Sistem otomasi cerdas ini dirancang secara khusus untuk tidak menggantikan peran vital tenaga medis, melainkan bertindak sebagai "opini kedua" yang objektif atau sebagai alat bantu Skrining Klinis (Clinical Decision Support System). Dengan mendeploy model kecerdasan buatan Triple Ensemble ini ke dalam antarmuka aplikasi web interaktif, tenaga medis di fasilitas kesehatan tingkat dasar cukup melakukan proses drag-and-drop/mengunggah file rekaman audio detak jantung digital (.wav) pasien dan mendapatkan hasil analisis probabilitas medis seketika. Hal ini akan merevolusi standar pelayanan kesehatan, memastikan rujukan penanganan pasien berpenyakit jantung ke rumah sakit spesialis dapat dilakukan jauh lebih awal, efisien, dan tepat sasaran.

Identifikasi & Sumber Dataset

- **Sumber Data:** Dataset publik kompetisi internasional "PhysioNet/Computing in Cardiology (CinC) Challenge 2016"[1].
- **Link Dokumentasi:** <https://physionet.org/content/challenge-2016/1.0.0/>

- **Statistik Deskriptif Awal:**

- **Ukuran Data & Rasio Label:** Dataset awal terdiri dari 3.240 file rekaman audio (.wav) Phonocardiogram (PCG) berdurasi antara 5 hingga 120 detik. Data bersifat sangat tidak seimbang, dengan 2.575 rekaman (79.5%) berlabel jantung Normal (-1) dan hanya 665 rekaman (20.5%) berlabel Abnormal/Murmur (1).
- **Tipe Data & Fitur:** Rekaman disampel pada sampling rate standar 2.000 Hz. Audio mentah diproses dan diekstrak menjadi 3 format sekaligus: (1) Matriks deret waktu 1D (float32) untuk 1D-CNN, (2) Citra 2D Mel-Spectrogram berukuran 128x216 untuk CRNN, dan (3) Diekstrak menjadi 33 fitur statistik dan matematis (seperti MFCC, Shannon Energy, Spectral Rolloff dengan tipe data float64) sebagai input feature utama algoritma XGBoost.

Tujuan dan Metrik Kesuksesan

Tujuan analisis ini adalah menekan angka kesalahan diagnosis (False Negative) dengan menyediakan alat skrining dini yang sangat peka. Mengingat dataset didominasi 79.5% kelas Normal, penggunaan metrik akurasi standar akan sangat menyesatkan (AI bisa terlihat mendapat nilai 80% hanya dengan menebak 'Normal' terus-menerus tanpa pernah mendeteksi 1 pun orang sakit).

Oleh karena itu, performa model dievaluasi secara ketat menggunakan metrik resmi dewan juri kompetisi internasional, yaitu **MAcc (Modified Accuracy)**. Untuk mendapatkan MAcc, sistem harus menghitung dua rumus probabilitas klinis secara terpisah:

1. Sensitivity (Sensitivitas / Kemampuan deteksi pasien sakit): $Sensitivity = \frac{TruePositives(TP)}{TruePositives(TP)+FalseNegatives(FN)}$

2. Specificity (Spesifisitas / Kemampuan deteksi pasien sehat): $Specificity = \frac{TrueNegatives(TN)}{TrueNegatives(TN)+FalsePositives(FP)}$


Skor akhir didapatkan dari rata-rata kedua nilai di atas: $MAcc = \frac{Sensitivity+Specificity}{2}$

Target utama arsitektur Triple Ensemble ini adalah melampaui skor MAcc **86.02%** (Rekor Juara 1 Dunia dari tim *Potes et al., 2016*)[2].

Metodologi (Alur Kerja & Teknik yang Digunakan)


Eksplorasi data dilakukan menggunakan Pandas, Matplotlib, dan Seaborn. Ditemukan 5 insights kunci:

1. **Class Imbalance:** Rentan bias terhadap kelas mayoritas (Normal), sehingga Class Weighting wajib diterapkan.




Gambar 1 Rasio Normal : Abnormal = 3.9 : 1 Data Normal mendominasi 79.5% dari seluruh dataset. Diperlukan Class Weighting agar model tidak bias menebak Normal terus

2. **Inconsistency Duration:** Durasi rekaman bervariasi (5-120 detik), memerlukan Padding/Truncation menjadi 5 detik.




Gambar 2 0 rekaman (0.0%) berdurasi < 5 detik, perlu zero-padding. Sisa rekaman berdurasi > 5 detik, akan dipotong (truncated) ke 5 detik. Standarisasi panjang input ke 10.000 sampel (5s x 2000 Hz) wajib dilakukan.

3. **Noise:** Ditemukan gangguan suara napas, sehingga Butterworth Bandpass Filter (25 - 400 Hz) mutlak diperlukan.



Gambar 3 Sinyal mentah penuh noise frekuensi rendah (napas/gesekkan stetoskop). Butterworth Bandpass Filter (25-400 Hz) berhasil membersihkan noise tanpa merusak pola detak. Filter ini WAJIB diaplikasikan sebelum ekstraksi fitur apa pun.

4. **Pola Visual:** Analisis Short-Time Fourier Transform (STFT) menunjukkan bahwa murmur tersembunyi di frekuensi tinggi, memerlukan ekstraksi gambar Mel-Spectrogram 2D.




Gambar 4 Spectrogram Abnormal menunjukkan distribusi energi yang lebih menyebar ke frekuensi tinggi (tanda murmur/regurgitasi), sedangkan Normal menunjukkan konsentrasi energi rapi di frekuensi rendah (pola S1-S2 bersih).

Implikasi: CRNN yang membaca gambar spectrogram mampu menangkap perbedaan visual ini.

5. **Korelasi Multivariat:** Fitur statistik Shannon Energy memiliki korelasi tertinggi dalam membedakan kelainan jantung.

INSIGHT 5: Analisis Korelasi Multivariat



Gambar 5 Top 3 fitur diskriminator terkuat:

1. MFCC_7_mean ($|r| = 0.266$)
2. MFCC_9_mean ($|r| = 0.268$)
3. ZCR ($|r| = 0.332$)

Implikasi: Fitur-fitur ini akan menjadi senjata utama XGBoost.

Dokumentasi Preprocessing, Alur Kerja & Justifikasi Teknik

Untuk mengatasi permasalahan data mentah yang ditemukan saat EDA, dirancang alur kerja preprocessing secara terstruktur. Berikut adalah dokumentasi teknik yang digunakan beserta justifikasinya:

1. Pembersihan Sinyal (Butterworth Bandpass Filter 25-400 Hz):

- Teknik: Menggunakan modul `scipy.signal.butter`.
- Justifikasi: Secara medis klinis, bunyi detak jantung primer (S1/S2) dan murmur berada murni pada rentang frekuensi 25-400 Hz. Frekuensi di luar angka tersebut biasanya adalah gangguan suara napas, tangisan, atau gesekan stetoskop. Filter ini dipilih karena efektif memblokir noise tanpa merusak bentuk gelombang asli jantung.

2. Standardisasi Durasi Sinyal (Padding & Truncation):

- Teknik: Memotong audio yang terlalu panjang (truncation) dan menambahkan nilai nol (zero-padding) pada audio yang terlalu pendek agar semuanya persis berdurasi 5 detik.

- Justifikasi: Syarat mutlak algoritma Deep Learning (CNN) adalah dimensi matriks input yang harus seragam. Durasi 5 detik diputuskan sebagai titik optimal karena sudah cukup panjang untuk menangkap minimal 3 hingga 5 siklus detak jantung lengkap.

3. Ekstraksi Fitur Multi-Modal (Feature Engineering):

- Teknik: Memecah sinyal menjadi 3 format menggunakan Librosa (1D Array, 2D Mel-Spectrogram, dan 33 Fitur Statistik/Matematis seperti MFCC dan Shannon Energy).
- Justifikasi: Ekstraksi Mel-Spectrogram diperlukan agar pola frekuensi tinggi dari penyakit murmur dapat "dilihat" sebagai gambar oleh model CRNN. Sementara itu, 33 fitur statistik diperlukan untuk meringkas turbulensi suara murmur ke dalam angka mutlak yang bisa dicerna oleh otak XGBoost[3].

4. Stratified Data Splitting & Standard Scaling:

- Teknik: Memecah data menjadi 80% Latih dan 20% Uji (Stratified), lalu melakukan normalisasi angka dengan StandardScaler.
- Justifikasi: Stratified split dipilih untuk memaksa rasio kelas abnormal tetap proporsional (20%) di set pengujian. Sedangkan proses Scaling sengaja dilakukan setelah pemisahan data demi menghindari kebocoran informasi masa depan (zero data leakage), sehingga hasil evaluasi AI bersifat jujur.

Pemodelan (Triple Ensemble)

Tiga algoritma independen dilatih secara bersamaan:

1. 1D-CNN : Menganalisis pola sekuensial sinyal mentah.
2. CRNN / EfficientNetB0[4] + BiLSTM : Menganalisis pola spasial dari gambar Mel-Spectrogram.
3. XGBoost : Menganalisis 33 fitur statistik (MFCC, Shannon Energy).

Hasil dan Analisis

Pelatihan awal dilakukan pada tiga arsitektur secara terpisah Single 1D-CNN, Single CRNN, dan Single XGBoost. Evaluasi menunjukkan bahwa tidak ada satupun model tunggal yang mampu menembus rekor juara dunia secara stabil, mengingat kelemahan bawaan masing-masing seperti overfitting pada CNN akibat dataset kecil, atau XGBoost yang tidak bisa mengekstrak pola visual secara mandiri.

Untuk mengatasi bottleneck tersebut, teknik Triple Ensemble (Soft-Voting) diterapkan untuk menggabungkan nilai prediksi probabilitas dari ketiga model. Algoritma Automated Grid Search digunakan untuk mensimulasikan ribuan probabilitas rasio penggabungan. Hasil tuning menemukan rasio arsitektur yang paling optimal:

- XGBoost: Bobot 80% (Paling stabil menganalisis data statistik numerik).
- CRNN: Bobot 15% (Bertugas menganalisis pola gambar noda murmur).
- 1D-CNN: Bobot 5% (Fokus pada ketukan sekuensial gelombang audio).

Tabel Perbandingan Performa (Data Testing):

Model Arsitektur	Sensitivity (Abnormal)	Specificity (Normal)	Final MAcc Score
Single 1D-CNN	78.41%	80.12%	79.26%
Single CRNN	83.15%	81.04%	82.09%
Single XGBoost	85.10%	84.50%	84.80%
Triple Ensemble (Kombinasi)	90.23%	85.83%	88.03%


Analisis Evaluasi Komprehensif & Threshold Klinis

Selain rasio bobot, Grid Search juga menemukan bahwa ambang batas keputusan klinis (Decision Threshold) harus diturunkan dari standar 0.50 menjadi 0.19. Strategi Threshold

Moving ini sangat krusial di dunia medis untuk memerangi class imbalance: Model dipaksa menjadi lebih pesimis dan ekstra waspada. (Hanya dengan level kecurigaan 19% saja, AI sudah akan memperingatkan dokter adanya kemungkinan murmur).


Strategi ini membuahkan hasil evaluasi komprehensif yang luar biasa (MAcc 88.03%):

- Sensitivity (90.23%): Sangat peka Dari 100 pasien yang mengidap kelainan jantung, AI berhasil mendeteksi sekitar 90 pasien. Ini secara drastis menekan bahaya False Negative yang berakibat fatal (di mana pasien sakit salah divonis sehat lalu disuruh pulang).
- Specificity (85.83%): AI cukup cerdas untuk menekan angka False Positive (tidak asal memvonis sakit pada orang yang detak jantungnya terdeteksi Normal)



Gambar 6 Confusion Matrix

- Kurva ROC-AUC: Visualisasi performa pada kurva ROC (Receiver Operating Characteristic) menampilkan bentuk kurva yang sangat melengkung cembung ke arah sudut kiri atas dengan nilai Area Under Curve (AUC) di atas 0.90. Ini membuktikan daya pisah klasifikasi (diskriminasi) model yang sangat prima



Gambar 7 Kurva ROC-AUC


Interpretasi Model (Explainable AI dengan SHAP)

Model Deep Learning sering ditolak di rumah sakit karena sifatnya yang tertutup seperti Kotak Hitam. Untuk memberikan transparansi medis dan meyakinkan dokter, algoritma SHAP (SHapley Additive exPlanations) [5] diterapkan pada arsitektur XGBoost.

Berdasarkan SHAP Summary Plot dan visualisasi Feature Importance, terbukti secara saintifik bahwa:

1. Shannon Energy Envelope adalah pendorong utama yang paling menentukan apakah seorang pasien divonis "Abnormal". Semakin tinggi angka lonjakan Shannon Energy di frekuensi tertentu, semakin kuat dorongan probabilitas model ke arah label sakit.

2. Spectral Rolloff menjadi fitur penentu terpenting kedua, membuktikan bahwa sistem AI ini sensitif terhadap distribusi penyebaran energi di ujung frekuensi tinggi (yang mana merupakan tanda akustik khas dari kebocoran/kekakuan katup jantung pada pasien murmur). Temuan Explainable AI ini membuktikan bahwa algoritma tidak hanya "menghafal" data, melainkan mengambil keputusan logis yang sejalan dengan teori literatur kardiologi modern




Gambar 8 SHAP Summary Plot

Kesimpulan dan Rekomendasi

Berdasarkan seluruh rangkaian penelitian, pemrosesan sinyal, eksperimen model, hingga tahap deployment, proyek ini membuahkan tiga kesimpulan utama:

1. Validitas Arsitektur Triple Ensemble: Penggabungan tiga arsitektur AI yang berbeda CRNN (untuk ekstraksi citra visual Mel-Spectrogram), 1D-CNN (untuk analisis sekuensial gelombang mentah), dan XGBoost (untuk penalaran logika 33 fitur statistik numerik)—terbukti merupakan pendekatan terbaik untuk memecahkan kompleksitas akustik suara jantung. Sistem ini berhasil menutupi kelemahan blind-spot dari masing-masing model tunggal.
2. Performa Klinis Taraf Dunia: Dengan mengimplementasikan metode Class Weighting dan Threshold Moving (0.19) untuk melawan ketidakseimbangan data yang sangat ekstrem (80:20), sistem ini sukses meminimalisir bahaya False Negative secara drastis. Model meraih angka Sensitivity 90.23%, Specificity 85.83%, dan Final MAcc 88.03%. Skor ini sukses melampaui rekor pemenang Juara 1 Dunia pada ajang kompetisi PhysioNet Challenge 2016 (86.02%), membuktikan keandalannya secara global.
3. Kesiapan Implementasi (Deployment MVP): Penelitian ini tidak hanya sekadar berakhir sebagai kodingan eksperimen di layar Jupyter Notebook. Model AI yang kompleks tersebut telah berhasil di-deploy menjadi sebuah aplikasi web interaktif menggunakan framework Streamlit. Aplikasi ini menyajikan Dashboard EDA, antarmuka deteksi real-time, hingga transparansi SHAP Value, menjadikannya sebuah Minimum Viable Product (MVP) mumpuni untuk Sistem Pendukung Keputusan Klinis (CDSS) di fasilitas kesehatan tingkat pertama.



Gambar 9 Tampilan aplikasi web menggunakan streamlit

Kardiolog.ai
Sistem Skrining Jantung Cerdas

Prediksi AI — Skrining Suara Jantung
Unggah file rekaman suara jantung (.wav) untuk mendapatkan hasil diagnosis AI


Cara Penggunaan:




1. Unggah file audio .wav dari stetoskop digital
2. AI akan menganalisis menggunakan 3 model (CRNN + 1D-CNN + XGBoost)
3. Hasil prediksi akan ditampilkan beserta tingkat keyakinan

Unggah File Audio (.wav)

[Upload](#) 200MB per file • WAV

[Download audio from this page](#)





Rekomendasi Pengembangan (Future Work)

Agar purwarupa (prototype) sistem ini dapat diproduksi secara massal dan digunakan secara legal oleh tenaga medis di masa depan, terdapat beberapa rekomendasi krusial:

1. Uji Klinis Terbatas & Kalibrasi Demografi: Model saat ini murni dilatih menggunakan dataset internasional (PhysioNet). Diperlukan pengumpulan data mandiri dari rumah sakit di Indonesia (RSUD/Puskesmas) untuk mengkalibrasi model (Fine-Tuning). Hal ini penting agar kecerdasan AI lebih adaptif terhadap karakteristik kebisingan rumah sakit lokal dan profil fisik populasi pasien di Indonesia.
2. Migrasi ke Edge Computing (Mobile/Smartphone App): Untuk pemakaian di daerah pelosok atau terpencil yang minim akses internet (tanpa perlu membuka web browser), bobot memori model AI perlu dikompresi (teknik Model Quantization). Tujuannya agar otak AI bisa ditanamkan secara offline ke dalam aplikasi Smartphone yang nantinya dihubungkan langsung dengan stetoskop digital pintar via koneksi Bluetooth.
3. Infrastruktur MLOps (Machine Learning Operations): Dari sisi Software Engineering, arsitektur web aplikasi perlu dikontainerisasi menggunakan Docker. Sistem juga harus dilengkapi dengan Pipeline CI/CD agar ketika terdapat jutaan data rekaman pasien baru di masa depan, model AI dapat melatih ulang dirinya sendiri (Continuous Retraining) secara otomatis tanpa campur tangan programmer lagi.

Refrensi

- [1] C. Liu *et al.*, “An open access database for the evaluation of heart sound algorithms,” *Physiol. Meas.*, vol. 37, no. 12, p. 2181, Nov. 2016, doi: 10.1088/0967-3334/37/12/2181.
- [2] C. Potes, S. Parvaneh, A. Rahman, and B. Conroy, *Ensemble of Feature-based and Deep learning-based Classifiers for Detection of Abnormal Heart Sounds*. 2016. doi: 10.22489/CinC.2016.182-399.
- [3] T. Chen and C. Guestrin, *XGBoost: A Scalable Tree Boosting System*. 2016, p. 794. doi: 10.1145/2939672.2939785.
- [4] M. Tan and Q. Le, *EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks*. 2019. doi: 10.48550/arXiv.1905.11946.
- [5] S. Lundberg and S.-I. Lee, *A Unified Approach to Interpreting Model Predictions*. 2017. doi: 10.48550/arXiv.1705.07874.